



Casos de Uso de Modelos LLaMA de Meta en el Sector Gobierno

Integración con sistemas **RAG On-premise e Híbridos**
para potenciar la administración pública moderna en LATAM

BUENOS AIRES
OCTUBRE 2025

Introducción

Los modelos **LLaMA de Meta** están transformando la administración pública al ofrecer una combinación única de **potencia**, **flexibilidad** y **control** que no existía previamente en el ecosistema de IA.

- ✓ Código abierto que permite despliegues seguros en infraestructuras gubernamentales sin dependencia de proveedores externos
- ✓ Capacidad multimodal y multilingüe que facilita el procesamiento de documentación pública en diversos formatos
- ✓ Cumplimiento de estándares de soberanía tecnológica y normativas de privacidad de datos sensibles
- ✓ Reducción significativa de costos operativos en comparación con soluciones propietarias tradicionales



Transformando la
administración pública
mediante IA abierta y
soberanía de datos

¿Qué es LLaMA de Meta?

LLaMA (Large Language Model Meta AI) es una familia de modelos de lenguaje de gran tamaño de código abierto desarrollada por Meta, que combina capacidades avanzadas con la posibilidad de **despliegue local**, lo que la hace especialmente adecuada para **casos de uso gubernamentales**.

-  Procesamiento multimodal de texto, imágenes, audio y video, permitiendo análisis integral de documentación gubernamental
-  Arquitectura escalable desde 8B hasta 400B parámetros, con opciones para infraestructuras de diversos tamaños
-  Aprobación oficial para uso en agencias gubernamentales, con adaptaciones específicas para requisitos de seguridad nacional
-  Capacidad de ejecución on-premise sin dependencia de conectividad a internet, ideal para entornos seguros

Familia de modelos LLaMA

LLaMA 4

Multimodal
nativo (2025)

LLaMA 3

Alto
rendimiento
(2024)

LLaMA 2

Licencia comercial
(2023)

Ventajas clave de LLaMA para gobiernos



Código abierto y personalizable

Posibilidad de modificar y adaptar los modelos a necesidades específicas gubernamentales sin dependencia de proveedores externos. Favorece la soberanía tecnológica y reduce costos a largo plazo.



Escalabilidad local (on-premise)

Capacidad de ejecutar desde dispositivos individuales hasta infraestructuras complejas gubernamentales. Flexibilidad para escalar vertical u horizontalmente según necesidades de cada agencia.



Control total de datos

Los datos sensibles nunca abandonan la infraestructura controlada por la agencia gubernamental. Cumplimiento estricto de normativas de privacidad y clasificación de seguridad.

"La naturaleza de código abierto de LLaMA permite su despliegue en entornos **completamente on-premise**, garantizando que los datos sensibles gubernamentales nunca abandonen la infraestructura controlada por la agencia."

Casos de uso principales en el sector público



1. Análisis y procesamiento de documentos

Automatización del análisis de contratos, formularios ciudadanos y documentos legislativos en múltiples formatos (texto, video, imágenes y audio).



2. Servicios ciudadanos mejorados

Chatbots y asistentes virtuales 24/7 que proporcionan respuestas precisas sobre servicios públicos, trámites y procedimientos administrativos.



3. Automatización de procesos administrativos

Aceleración de revisión de contratos, resolución de problemas de TI y automatización de tareas de cumplimiento normativo.



4. Seguridad nacional y defensa

Análisis de inteligencia, planificación logística, seguimiento de financiamiento terrorista y fortalecimiento de defensas cibernéticas.



5. Análisis de políticas públicas

Procesamiento y análisis de documentos de política, registros legislativos y estudios de impacto para el desarrollo de políticas basadas en evidencia.

Desafíos: Ciberseguridad, datos y ética

Protección de infraestructura

- 🛡️ Infraestructuras críticas: Protección de sistemas gubernamentales y servicios esenciales contra ciberataques
- 🔒 Seguridad de datos sensibles: Implementación de protocolos avanzados de encriptación y sistemas de detección de intrusiones
- ⚠️ Gestión de riesgos: Evaluación continua de vulnerabilidades y planes de respuesta a incidentes en entidades públicas

Gobernanza de datos y ética

- 📋 Gobierno de datos públicos: Gestión transparente y responsable de información gubernamental, con políticas claras de acceso y uso
- ⚖️ Consideraciones éticas: Implementación de marcos éticos para IA que eviten sesgos, discriminación y garanticen transparencia algorítmica
- 👤 Privacidad ciudadana: Protección de datos personales bajo estándares internacionales adaptados al contexto latinoamericano

DESAFÍO REGIONAL

La brecha entre avances tecnológicos y marcos regulatorios representa un desafío crítico que requiere actualización constante y colaboración entre sectores público, privado y académico

Servicios ciudadanos mejorados

La implementación de **chatbots y asistentes virtuales** potenciados por LLaMA está transformando la interacción entre ciudadanos y gobierno, permitiendo acceso a servicios públicos **24/7** con respuestas precisas y personalizadas.

65%

Reducción en tiempos de respuesta

24/7

Disponibilidad continua

78%

Satisfacción ciudadana



Atención inmediata y personalizada para trámites frecuentes como licencias, permisos y documentación



Capacidad multilingüe para atender poblaciones diversas y visitantes internacionales



Actualización automática con la información gubernamental más reciente, normativas y plazos

Asistentes virtuales que transforman la experiencia ciudadana con acceso inmediato a información y servicios

Automatización de Procesos Administrativos

Las agencias gubernamentales están desplegando **LLaMA** para automatizar tareas administrativas complejas, permitiendo que los empleados públicos se concentren en actividades estratégicas de **mayor valor**, mejorando significativamente la **eficiencia operativa**.



Revisión de contratos:

Aceleración del análisis de documentos legales para identificar cláusulas críticas, inconsistencias o riesgos potenciales.



Resolución de problemas TI:

Asistentes virtuales para soporte técnico interno que diagnostican problemas comunes y proponen soluciones inmediatas.



Automatización normativa:

Monitoreo continuo de cumplimiento regulatorio y generación automatizada de reportes de conformidad.



Beneficios comprobados:

Reducción de hasta 65% en tiempo de procesamiento administrativo y disminución significativa de errores humanos. (GSA OneGov, 2025)



Seguridad Nacional y Defensa

Meta ha extendido el acceso a los modelos **LLaMA** para aplicaciones críticas de **seguridad nacional**, fortaleciendo las capacidades defensivas del Estado.

-  Análisis de inteligencia y procesamiento de datos clasificados en entornos aislados
-  Planificación logística y optimización de recursos en operaciones de defensa
-  Seguimiento de financiamiento terrorista mediante análisis de patrones complejos
-  Fortalecimiento de defensas cibernéticas mediante detección proactiva de amenazas



Potenciando la defensa nacional con IA abierta y segura

AI Factory – Lockheed Martin (2024–2025)

Integración de LLaMA en plataforma para desarrollo acelerado de productos aeroespaciales. Incluye LMText Navigator: procesamiento seguro on-premise con más de 40.000 empleados beneficiados.

Análisis de políticas públicas y legislativas

Los modelos **LLaMA** están siendo empleados para analizar documentos de política, registros legislativos y estudios de impacto, proporcionando **soporte basado en evidencia** para el desarrollo de políticas públicas.

Caso LLaMandement-13B en Francia

- 🔑 Modelo finetuneado sobre LLaMA-2-13B específicamente para resumir y analizar propuestas legislativas francesas
- 🔍 Capacidad para identificar argumentos, clasificar tipos de enmiendas y generar resúmenes neutrales de alto valor jurídico
- 🔗 Liberado en Hugging Face como código abierto, promoviendo transparencia y reproducibilidad científica

Fuente: AgentPublic/LLaMandement-13B (2024)



Mejorando el desarrollo de políticas públicas mediante el análisis inteligente de documentación legislativa



Análisis y síntesis documental con precisión jurídica

¿Qué es RAG? (Retrieval Augmented Generation)

RAG, o **Retrieval Augmented Generation**, es una arquitectura que combina la recuperación de información (retrieval) con la generación de texto mediante modelos de lenguaje como LLaMA, mejorando precisión y confiabilidad al **fundamentar respuestas en datos específicos**.

 **Bases de conocimiento controladas:**
Integra documentos gubernamentales, leyes, normativas y datos específicos de cada institución


 **Contextualización precisa:**
Reduce alucinaciones al basar respuestas en fuentes verificadas y actualizadas

 **Flexibilidad de despliegue:**
Implementación on-premise (máxima seguridad), híbrida (flexibilidad) o cloud (escalabilidad)

 **Adaptabilidad normativa:**
Actualización automática ante cambios legislativos o procedimentales en la administración pública



Arquitectura RAG on-premise



Soberanía de Datos

Control total sobre información sensible dentro de la infraestructura gubernamental



Personalización Avanzada

Integración con bases de conocimiento especializadas y sistemas legacy existentes



Seguridad y Compliance

Cumplimiento estricto de regulaciones locales de residencia de datos y clasificación

Caso de éxito: Espacio Llama (NASA, 2025)

Desarrollo de un modelo **LLaMA 3.2 personalizado** para operar en la **Estación Espacial Internacional** sin conectividad a internet, permitiendo procesamiento local de datos críticos.



Alcanzó el nivel **TRL 8**

(Technology Readiness Level) de la NASA, certificando su operación completa y confiable en el entorno espacial



Permite a astronautas procesar y analizar imágenes, realizar mantenimiento predictivo y acceder a documentación técnica sin depender de comunicaciones terrestres



Redujo tareas de IA de **varios minutos a poco más de un segundo**, optimizando operaciones críticas en entornos con recursos limitados



Implementado con protocolos avanzados de seguridad para proteger operaciones confidenciales en misiones espaciales



Operación autónoma en la
Estación Espacial
Internacional

TRL 8

Nivel de Preparación
Tecnológica NASA

Caso de éxito: Proyecto LatamGPT

12

Países a través de
30 instituciones
colaborando

70B

de parámetros bajo
licencia de código
abierto

2B

de tokens
comparable a
modelos globales

+8 TB

de información
regional de 21
países de LATAM



Latam-GPT

Un modelo de lenguaje hecho en Latinoamérica, para
Latinoamérica.

LatamGPT basado en **LLaMa 3** está en fase piloto con versiones en lenguas indígenas y pruebas públicas de benchmarks, sosteniendo alianzas con centros universitarios, gobiernos, ONGs y empresas tecnológicas regionales. [TheRevolution.news](https://www.therevolution.news)

Fuente: [ACAL](https://www.acal.org)

Caso de éxito: Proyecto LatamGPT

Implementación LLaMA 3.1

LatamGPT representa una adaptación exitosa del modelo LLaMa 3.1 de Meta, específicamente ajustado al contexto lingüístico, cultural y administrativo latinoamericano

85 %

Precisión en
contexto regional

3.8TB

Datos
latinoamericanos

+40 %

Eficiencia vs
modelos genéricos

Fine-tuning especializado:

Ajustes específicos para comprender modismos, marcos legales y contextos administrativos de la región

Resultados tangibles

- ✓ Reducción de tiempos: Disminución del 67 % en tiempos de procesamiento documental en entidades públicas de 5 países
- ✓ Atención ciudadana: Implementación en 28 municipalidades con 92 % de satisfacción ciudadana en consultas automáticas
- ✓ Costos operativos: Ahorro promedio del 43 % en recursos administrativos dedicados a tareas repetitivas

LECCIONES APRENDIDAS

La implementación exitosa requirió colaboración intergubernamental, datos locales de calidad y capacitación del personal. El enfoque gradual por fases demostró ser clave para la adopción efectiva en entidades con diferentes niveles de madurez digital

Caso de éxito: AI Factory – Lockheed Martin (2024–2025)

Integración de modelos **LLaMA** en la plataforma AI Factory de Lockheed Martin, potenciando el desarrollo aeroespacial y de defensa mediante IA generativa accesible en entornos seguros **on-premise**.



Desarrollo de **LMText Navigator**, una herramienta de IA generativa que procesa grandes cantidades de datos de múltiples fuentes de forma segura y on-premise.



El equipo de **Skunk Works** creó un experto virtual que permitió a los ingenieros comprender rápidamente los principios del Entorno de Simulación Conjunta (JSE) gubernamental.



Aceleración en el desarrollo de código compatible para integrar modelos en sistemas gubernamentales de alta seguridad.



Procesamiento de información clasificada sin exposición a redes externas gracias a la ejecución local de LLaMA.



40,000+

Empleados utilizan actualmente la capacidad en Estados Unidos

Caso de éxito: GSA OneGov – Gobierno Federal EEUU

 Implementación a escala federal (2025)

La **Administración de Servicios Generales (GSA)** aprobó oficialmente los modelos LLaMA para uso en todas las agencias federales estadounidenses, integrándolos en su iniciativa **OneGov**.



Implementación en revisión automatizada de contratos federales, reduciendo el tiempo de análisis en un 78% y mejorando la precisión de evaluación



Despliegue en resolución de problemas de TI a nivel federal, proporcionando asistencia técnica continua a funcionarios



Automatización de tareas de cumplimiento normativo con verificación de compatibilidad con más de 200 regulaciones federales



Establecimiento de un precedente histórico para la adopción de modelos de IA de código abierto en el gobierno federal



Primera plataforma de IA generativa oficialmente autorizada para uso federal en todas las agencias

Caso de éxito: LLaMandement-13B, Francia (2024)

El gobierno francés desarrolló **LLaMandement-13B**, un modelo específicamente entrenado para resumir y analizar propuestas legislativas francesas, basado en **LLaMA-2-13B**.



Capacidad avanzada para identificar argumentos jurídicos, clasificar tipos de enmiendas y generar resúmenes neutrales con alto valor legal



Reducción del tiempo de análisis legislativo en un 78%, permitiendo respuestas más ágiles a propuestas complejas



Liberado públicamente en Hugging Face como "Agent Public/LLaMandement-13B", promoviendo transparencia y reproducibilidad científica



Adoptado internamente en múltiples niveles de la administración francesa para democratizar el acceso a análisis legislativo



Modelo fine-tuneado sobre LLaMA-2-13B especializado en procesamiento legislativo y jurídico francés

Modelos Especializados en Seguridad

LLaMA Guard 3-8B

Modelo de salvaguarda para conversaciones IA-Humano

-  Fine-tuneado sobre Llama-3.1-8B para clasificación de seguridad de contenido
-  Evalúa tanto inputs (prompts) como outputs (respuestas) para detectar contenido inapropiado
-  Gestiona 8 categorías de riesgo específicas incluidas en regulaciones gubernamentales
-  Disponible como modelo open-source para despliegues on-premise con seguridad máxima

Prompt Guard 86M

Clasificador especializado contra ataques de prompt injection

-  Modelo ligero de 86M parámetros entrenado en corpus masivo de ataques conocidos
-  Detecta tanto prompts explícitamente maliciosos como datos con jailbreaks ocultos
-  Procesamiento ultrarrápido para validación en tiempo real sin impacto en latencia
-  Actualizado regularmente con nuevos vectores de ataque detectados en entornos reales

Aplicaciones en Entornos Gubernamentales

-  Cumplimiento de políticas de seguridad nacional
-  Protección de datos ciudadanos sensibles
-  Integración con LlamaFirewall para orquestación de defensa
-  Monitoreo continuo de amenazas emergentes

Oportunidades y desafíos en Argentina

Oportunidades

- ✓ Modernización de servicios públicos con **autonomía tecnológica** y menor costo que soluciones propietarias
- ✓ Desarrollo de talento local en **IA aplicada al sector público**, fortaleciendo el ecosistema tecnológico nacional
- ✓ Integración con **sistemas existentes** en ministerios y administraciones provinciales sin depender de proveedores externos
- ✓ Posicionamiento de Argentina como **referente regional** en gobierno digital impulsado por IA abierta

Desafíos

- Desarrollo de **marco regulatorio específico** para IA en administraciones públicas (siguiendo modelo europeo)
- Garantizar **infraestructura técnica** adecuada para despliegues on-premise en organismos públicos
- Capacitación del **talento humano** en el sector público para gestionar proyectos de IA efectivamente
- Desarrollo de **estrategia nacional** para adopción coordinada y eficiente de LLMs en el Estado

Modelo de adopción y ciclo de vida de proyectos IA/LLMs para Gobiernos

Fase 1: Identificación y evaluación de oportunidades

- 1.1 Identificación de la oportunidad**
Detección de barreras o áreas de mejora donde la IA aportaría valor significativo
- 1.2 Clasificación del nivel de riesgo**
Evaluación según AI Act y cuestionario específico de la entidad pública
- 1.3 Informe de evaluación del sistema**
Análisis de datos, recursos, costes, aspectos éticos y legales
- 1.4 Revisión del informe**
Validación multidisciplinar por la Comisión de Evaluación
- 1.5 Valoración final y decisión**
Aprobación, rechazo o solicitud de modificaciones al proyecto

→
Mejora
continua
←

Fase 2: Diseño, desarrollo e implantación

- 2.1 Ideación del sistema de IA**
Definición objetiva del problema y metas a alcanzar
- 2.2 Diseño del sistema**
Arquitectura, algoritmos, interfaces, requisitos éticos y normativos
- 2.3 Desarrollo y entrenamiento**
Calidad y suficiencia de datos, prevención de sesgos, documentación
- 2.4 Validación de resultados**
Pruebas con conjuntos independientes, métricas de desempeño
- 2.5 Despliegue y mantenimiento**
Monitorización continua, actualización y evaluación ética constante

Riesgo inaceptable

Prohibido por normativa (puntuación social, manipulación)



Delegado/a de IA

Riesgo alto

Requisitos estrictos, evaluaciones periódicas, supervisión humana



Comisión de Evaluación

Riesgo limitado

Obligaciones de transparencia y notificación a usuarios



Personal Funcional

Riesgo mínimo

Autorregulación y adhesión a códigos de conducta



Personal TI

Proyección de costos de infraestructura

Sistema de cálculo

Herramienta integral para estimar y proyectar inversiones en proyectos de IA gubernamentales, adaptada al contexto latinoamericano

-  **Componentes de hardware:** Infraestructura, servidores, almacenamiento y recursos computacionales necesarios
-  **Software y licencias:** Costos de desarrollo, implementación y mantenimiento de soluciones de IA
-  **Capital humano:** Inversión en capacitación, contratación de especialistas y consultorías técnicas



Amazon Bedrock



Factores de evaluación

Infraestructura

Evaluación escalonada según capacidad requerida, desde soluciones en la nube hasta implementaciones on-premise con equipos propios

Rendimiento

Análisis de costo-beneficio entre precisión del modelo, velocidad de respuesta y recursos computacionales necesarios

Escalabilidad

Proyección de costos incrementales según crecimiento del proyecto y volumen de usuarios esperados

ROI PARA GOBIERNOS

El sistema permite calcular el retorno de inversión considerando ahorros en recursos humanos, eficiencia en procesos y mejora en servicios públicos, con períodos de recuperación estimados entre 12 y 24 meses

Buenas prácticas para la gestión responsable de IA en sector público

Una implementación responsable de IA en administraciones públicas requiere un enfoque integral que garantice transparencia, ética y cumplimiento normativo.

-  Evaluación de riesgos activa y multidimensional en cada fase del ciclo de vida
-  Comisiones colegiadas multidisciplinares para evaluación y validación
-  Documentación exhaustiva y gestión de la trazabilidad técnica
-  Cumplimiento continuo de regulaciones y principios éticos vigentes
-  Transparencia y trazabilidad de todas las decisiones durante el proyecto
-  Seguridad y privacidad como elementos transversales del desarrollo
-  Monitorización continua y actualización regular de modelos y controles
-  Retroalimentación constante de usuarios finales y partes interesadas

Conclusiones y próximos pasos

Beneficios clave para Argentina

-  **Soberanía tecnológica:** Control total de los datos sensibles gubernamentales sin dependencia de proveedores externos
-  **Eficiencia económica:** Reducción significativa de costos operativos frente a soluciones propietarias tradicionales
-  **Adaptabilidad:** Personalización a normativas, idioma y necesidades específicas de la administración pública argentina

Próximos pasos

-  Desarrollo de proyectos piloto con RAG on-premise en organismos públicos seleccionados
-  Formación de equipos técnicos especializados en implementación y gestión de LLMs
-  Elaboración de guías técnicas para ciclo de vida de proyectos basados en LLaMA



¿Preguntas?

Estamos a su disposición para resolver dudas técnicas y explorar posibles aplicaciones para su organización



AUGMENTED
EXPERIENCES

multi
versica
ACADEMY

LLAMA TALKS

AI, OPEN SOURCE Y DESAFÍOS PÚBLICOS

BUENOS AIRES
OCTUBRE 2025

[AUGEXP.COM](https://augexp.com) | [MULTIVERSICA.ACADEMY](https://multiversica.academy)

